KI-GOVERNANCE-TESTRAHMEN UND -TOOLKIT

ZUSAMMENFASSENDER BERICHT

BINÄRES KLASSIFIKATIONSMODELL FÜR KREDITRISIKO

ABC COMPANY PTE LTD

06. JUNI 2023

[Deutsche Übersetzung – Original: AI Verify Foundation, Sample Report]

EINLEITUNG

ZIEL DES AI-VERIFY-KI-GOVERNANCE-TESTRAHMENS UND -TOOLKITS

AI Verify unterstützt Organisationen dabei, die Leistung ihrer KI-Systeme anhand einer Reihe international anerkannter Prinzipien durch standardisierte Tests zu validieren:

- die Leistung ihrer KI-Systeme; und
- dokumentarische Nachweise, dass ihre KI-Systeme mit Prozessen entwickelt und eingesetzt wurden, die darauf ausgelegt sind, die gewünschten Ergebnisse dieser Prinzipien zu erreichen.

Unternehmen können die Ergebnisse dieser Tests nutzen, um die Umsetzung verantwortungsvoller KI nachzuweisen und Vertrauen bei ihren Stakeholdern aufzubauen. Unternehmen können die Testergebnisse auch nutzen, um potenzielle Lücken zu identifizieren und, sofern zutreffend, geeignete Maßnahmen zu deren Behebung zu ergreifen.

Bitte beachten Sie, dass nur Berichte, die vom AI-Verify-Toolkit gemäß dem AI-Verify-Testrahmen und ohne Änderungen erstellt wurden, AI-Verify-Berichte sind.

GETESTETER ANWENDUNGSFALL UND MODELL

UMFANG DER PRÜFUNGEN

Dieser zusammenfassende Bericht bietet einen Überblick darüber, wie das KI-Modell im Vergleich zum AI-Verify-Testrahmen abschneidet. Der Rahmen umfasst 11 KI-Ethik-Prinzipien, gegliedert in 5 Schwerpunktbereiche.

Diese Prinzipien werden durch eine Kombination aus technischen Tests und/oder Prozessprüfungen bewertet.

Schwerpunktbereiche:

- Transparenz über den Einsatz von KI und KI-Systemen — Sicherstellen, dass Personen informiert sind und fundierte Entscheidungen treffen können
- Verständnis, wie KI-Modelle zu Entscheidungen gelangen — Sicherstellen, dass Betrieb/Ergebnisse erklärbar, genau und konsistent sind
- Sicherheit & Resilienz des KI-Systems — Sicherstellen, dass das System zuverlässig ist und keinen Schaden verursacht
- Fairness / keine unbeabsichtigte Diskriminierung — Sicherstellen, dass der Einsatz von KI nicht unbeabsichtigt diskriminiert
- Management und Aufsicht des KI-Systems — Sicherstellen menschlicher Verantwortlichkeit und Kontrolle

Getestetes Modell: Binäres Klassifikationsmodell für Kreditrisiko

Zweck des Modells: Dieses Modell wird verwendet, um zu testen, ob der Antragsteller den Kredit ausfallen lässt

AI VERIFYS 11 PRINZIPIEN

Bereich 1 — Sicherstellen, dass Personen informiert sind und fundierte Entscheidungen treffen können

Transparenz — Fähigkeit, gegenüber den von KI-Systemen Betroffenen verantwortungsvoll Auskunft zu geben, damit diese das Ergebnis verstehen können.

Bereich 2 — Sicherstellen, dass Betrieb/Ergebnisse der KI erklärbar, genau und konsistent sind

Erklärbarkeit — Fähigkeit, die Faktoren zu bewerten, die zur Entscheidung des KI-Systems geführt haben, sowie sein Gesamtverhalten, seine Ergebnisse und Implikationen.

Wiederholbarkeit/Reproduzierbarkeit — Die Fähigkeit eines Systems, seine erforderlichen Funktionen unter festgelegten Bedingungen über einen bestimmten Zeitraum konsistent auszuführen, und die Fähigkeit einer unabhängigen Partei, bei ähnlichen Eingaben dieselben Ergebnisse zu erzielen.

Bereich 3 — Sicherstellen, dass das KI-System zuverlässig ist und keinen Schaden verursacht

Sicherheit (Safety) — KI sollte keinen Schaden für Menschen verursachen (insbesondere physischen Schaden), und es sollten Maßnahmen zur Schadensminderung ergriffen werden.

Sicherheit (Security) — Schutz von KI-Systemen, ihren Daten und der zugehörigen Infrastruktur vor unbefugtem Zugriff, Offenlegung, Änderung, Zerstörung oder Störung.

Robustheit — Das KI-System sollte widerstandsfähig gegen Angriffe und Manipulationsversuche böswilliger Dritter sein und trotz unerwarteter Eingaben weiterhin funktionieren können.

Bereich 4 — Sicherstellen, dass der Einsatz von KI nicht unbeabsichtigt diskriminiert

Fairness — KI sollte nicht zu unbeabsichtigter und unangemessener Diskriminierung von Einzelpersonen oder Gruppen führen.

Data Governance — Governance der in KI-Systemen verwendeten Daten, einschließlich guter Praktiken für Datenqualität, -herkunft und -compliance.

Bereich 5 — Sicherstellen menschlicher Verantwortlichkeit und Kontrolle

Accountability (Verantwortlichkeit) — KI-Systeme sollten über Organisationsstrukturen und Akteure verfügen, die für ihr ordnungsgemäßes Funktionieren verantwortlich sind.

Menschliches Handeln & Aufsicht — Fähigkeit, geeignete Aufsichts- und Kontrollmaßnahmen mit Human-in-the-Loop an den passenden Stellen umzusetzen.

Inklusives Wachstum, gesellschaftliches & ökologisches Wohlergehen — Das Potenzial vertrauenswürdiger KI, zu umfassendem Wachstum und Wohlstand für Individuen, Gesellschaft und den Planeten beizutragen.

ZUSAMMENFASSUNG

GESAMTABSCHLUSSSTATUS

Technische Tests

- Erfolgreich durchgeführte Tests: 3 / 3
- Nicht abgeschlossene Tests: 0 / 3
- Vom Nutzer übersprungene Tests: 0 / 3

Prozessprüfungen

Das Unternehmen hat die Prozess-Checkliste mit 85 Prozessprüfungen abgeschlossen, davon:

- 32 Prozessprüfungen sind mit „Ja“ gekennzeichnet — dokumentarischer Nachweis für die Umsetzung liegt vor.
- 29 Prozessprüfungen sind mit „Nein“ gekennzeichnet — da nicht umgesetzt, besteht ggf. ein Risiko, das bewertet bzw. gemindert werden muss[1].
- 24 Prozessprüfungen sind mit „Nicht zutreffend“ gekennzeichnet[2].

[1] Das Unternehmen sollte regelmäßig überprüfen, ob die Gründe für die Nichtumsetzung weiterhin gültig sind und mit Werten, Zielen und regulatorischen Anforderungen übereinstimmen.

[2] Sollte sich Betriebsumfeld oder Modell ändern, sollte bewertet werden, ob diese Prozessprüfungen relevant werden könnten.

Diese Zusammenfassung bietet einen Überblick über das getestete KI-Modell. Details zu jedem Prinzip und deren Interpretation finden sich auf den folgenden Seiten.

INFORMATIONEN ZUM KI-MODELL

- Name des getesteten Modells: Binäres Klassifikationsmodell für Kreditrisiko
- Modelltyp: Klassifikation
- Modelldateiname: binary_classification_mock_credit_risk_sklearn.linear_model._logistic.LogisticRegression.sav
- Testdatensatz: pickle_pandas_mock_binary_classification_credit_risk_testing.sav
- Bericht erstellt: 06. Juni 2023, 12:03:62 Uhr

01 / TRANSPARENZ ÜBER DEN EINSATZ VON KI UND KI-SYSTEMEN

Sicherstellen, dass Personen informiert sind und fundierte Entscheidungen treffen können

Das Prinzip der Transparenz wurde anhand von 8 Prozessprüfungen bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zur Transparenz.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Den Endnutzern die notwendigen Informationen zur Nutzung ihrer personenbezogenen Daten bereitstellen, um sicherzustellen, dass diese in fairer und transparenter Weise verarbeitet werden
- Wo möglich (ohne IP, Sicherheit oder Systemintegrität zu gefährden), geeignete Zeitpunkte im KI-Lebenszyklus identifizieren, um Endnutzer/Betroffene über Zweck, Kriterien, Einschränkungen und Risiken der Entscheidung(en) zu informieren
- Informationen bereitstellen, um Endnutzer in zugänglicher Weise zur ordnungsgemäßen Nutzung des KI-Systems anzuleiten

Was das bedeutet:

Das Unternehmen sollte überprüfen, ob die derzeitigen Kommunikationsmechanismen ausreichen, um denjenigen, die das KI-System nutzen und/oder davon betroffen sind, zu ermöglichen, zu verstehen, wie ihre Daten erhoben und verwendet werden, sowie die beabsichtigte Nutzung und die Einschränkungen des KI-Systems.

Empfehlung(en):

Das Unternehmen kann in Erwägung ziehen, die Nutzer bzw. betroffenen Personen zu befragen, um herauszufinden, ob das derzeitige Informationsniveau angemessen ist, und falls nicht, die Informationslücke entsprechend zu schließen.

Ergebnisübersicht: 3 × Ja, 3 × Nein, 2 × Nicht zutreffend

02 / VERSTÄNDNIS, WIE KI-MODELLE ZU ENTSCHEIDUNGEN GELANGEN

Sicherstellen, dass Betrieb/Ergebnisse der KI erklärbar, genau und konsistent sind

Das Prinzip der Erklärbarkeit wurde anhand von 1 Prozessprüfung und einem technischen Test bewertet.

Zusammenfassende Begründung

Das Unternehmen hat keinen Grund angegeben.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Eine Präferenz für die Entwicklung von KI-Modellen zeigen, die ihre Entscheidungen erklären können oder standardmäßig interpretierbar sind

Was das bedeutet:

Wenn die Leistung verschiedener in Betracht gezogener Modelle ähnlich ist, das Unternehmen jedoch keine Präferenz für das besser erklärbare bzw. standardmäßig interpretierbare Modell zeigt, läuft es Gefahr, Stakeholdern nicht vermitteln zu können, wie das Modell zu seiner Empfehlung gelangt — was zu Vertrauensverlust führen kann.

Empfehlung(en):

Wählt das Unternehmen einen weniger erklärbaren Modellierungsansatz, sollte es seine Begründung dafür dokumentieren, unter Berücksichtigung regulatorischer Anforderungen, interner Richtlinien und des beabsichtigten Einsatzzwecks.

Ergebnisübersicht: 0 × Ja, 1 × Nein, 0 × Nicht zutreffend

TECHNISCHER TEST — Globales Erklärbarkeitsdiagramm

Der globale Erklärbarkeitstest zeigt die 8 wichtigsten Merkmale, die die Vorhersage des KI-Modells beeinflussen. Jeder Balken repräsentiert ein Merkmal, geordnet vom höchsten zum niedrigsten Beitrag (absoluter SHAP-Wert).

Was das bedeutet: Die Testergebnisse helfen dem Unternehmen, seinen Stakeholdern die Schlüsselfaktoren zu vermitteln, die die Modellempfehlung beeinflussen. Diese Merkmale tragen zu 100,00 % zu den finalen Vorhersagen bei.

- loan_amount
- income
- age
- gender
- race
- home_ownership
- prior_count
- loan_interests

Empfehlung(en): Das Unternehmen kann diese Faktoren mit Stakeholdern teilen, damit sie besser verstehen, wie das Modell Vorhersagen trifft. Würde die Weitergabe geistiges Eigentum, Vertraulichkeit, Sicherheit oder Systemintegrität gefährden, kann eine Gruppierung in generischere, nicht-sensible Kategorien erwogen werden.

03 / WIEDERHOLBARKEIT / REPRODUZIERBARKEIT

Das Prinzip der Wiederholbarkeit/Reproduzierbarkeit wurde anhand von 15 Prozessprüfungen bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zur Reproduzierbarkeit.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Maßnahmen zur Sicherstellung der Datenqualität im Zeitverlauf einführen
- Maßnahmen zum Verständnis der Datenherkunft einführen
- Das KI-Modell bzw. die Regeln nachverfolgen, die zur Entscheidung/Empfehlung geführt haben
- Angemessene Protokollierungspraktiken einführen
- Wiederholbarkeit beurteilen (gleiche Eingabe → gleiches Ergebnis)
- Prozess zur Modellentwicklung definieren und bewerten
- Strategie zur Reproduktion der Trainings-Eingabedaten etablieren
- Strategie etablieren, dass Annahmen auch nach Retraining gültig bleiben
- Bei Blackbox-/Drittanbietermodellen die Genauigkeitsangaben des Anbieters bewerten
- Strategie zur kontinuierlichen Qualitätsbewertung der Ausgaben etablieren

Was das bedeutet:

Das Unternehmen ist möglicherweise nicht in der Lage, dieselben Ergebnisse zu reproduzieren und die Konsistenz des Modellverhaltens nachzuweisen.

Empfehlung(en):

Das Unternehmen sollte Prozesse und Maßnahmen wie Protokollierungsfunktionen einführen, um die Reproduzierbarkeit des Trainingsprozesses zu ermöglichen, und die Konsistenz der verwendeten Daten über den gesamten Lebenszyklus nachverfolgen.

Ergebnisübersicht: 5 × Ja, 5 × Nein, 5 × Nicht zutreffend

SICHERHEIT & RESILIENZ DES KI-SYSTEMS (SAFETY)

Sicherstellen, dass das KI-System zuverlässig ist und keinen Schaden verursacht

Das Prinzip der Sicherheit (Safety) wurde anhand von 9 Prozessprüfungen bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zur Sicherheit (Safety).

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Risiken, Risikokennzahlen und Risikostufen je Anwendungsfall bewerten
- Prozess zur kontinuierlichen Risikobewertung/-überwachung einführen, inkl. neuer Risiken nach Bereitstellung
- Fehlertoleranz planen (dupliziertes/paralleles System)
- Restrisiken identifizieren und Risikotoleranz bewerten

Was das bedeutet:

Durch die Nichtumsetzung aller Kriterien kann das KI-System ein Schadensrisiko für Endnutzer bergen, das hätte gemindert werden können — dies kann das Gesamtvertrauen verringern.

Empfehlung(en):

Das Unternehmen sollte Prozesse zur kontinuierlichen Risikobewertung einführen und Risikobewertungen durchführen, um ausreichende Minderungsmaßnahmen nachzuweisen.

Ergebnisübersicht: 3 × Ja, 3 × Nein, 3 × Nicht zutreffend

SICHERHEIT & RESILIENZ DES KI-SYSTEMS (SECURITY)

Das Prinzip der Sicherheit (Security) wurde anhand von 14 Prozessprüfungen bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zur Sicherheit (Security).

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Sicherheitsrisikobewertung zu Beginn der Entwicklung durchführen
- Sicherheitsmaßnahmen während Verifizierung/Validierung einführen
- Sicherheitsmaßnahmen während Design/Entwicklung einführen
- Sicherheitsmaßnahmen während Bereitstellung/Überwachung einführen
- Sicherheitsmaßnahmen für kontinuierliches/Online-Lernmodell einführen
- Sicherheitsmaßnahmen für Ende der Lebensdauer einführen

Was das bedeutet:

Das KI-System des Unternehmens kann anfällig für Ausnutzung durch böswillige Akteure sein, was Vertraulichkeit, Integrität und Verfügbarkeit gefährdet — mit möglichen Folgen wie Datenschutzverletzungen, Betrug, Reputationsschäden und regulatorischen Konsequenzen.

Empfehlung(en):

Sicherheit ist zentral für Stakeholder-Vertrauen. Regelmäßig überprüfen, ob Gründe für Nichtumsetzung weiterhin gültig sind; da sich Bedrohungen schnell entwickeln, sollten Sicherheitsrisiken periodisch neu bewertet werden.

Ergebnisübersicht: 5 × Ja, 5 × Nein, 4 × Nicht zutreffend

ROBUSTHEIT

Das Prinzip der Robustheit wurde anhand von 7 Prozessprüfungen und einem technischen Test bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zur Robustheit.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Faktoren geringer Genauigkeit überprüfen und mögliche kritische/adversarielle Folgen bewerten
- Berücksichtigen, ob der Betrieb des Systems Trainingsannahmen ungültig machen kann
- Strategie zur Überwachung/Minderung von Blackbox-Angriffen etablieren

Was das bedeutet:

Das Unternehmen kann das Leistungsniveau möglicherweise nicht unter allen Umständen aufrechterhalten (z. B. bei Umgebungsänderungen oder adversariellen Akteuren), was zu schädlichen Folgen führen kann.

Empfehlung(en):

Maßnahmen und Prozesse zur Überwachung und Bewertung der Widerstandsfähigkeit gegenüber unerwarteten Eingaben einführen.

Ergebnisübersicht: 3 × Ja, 2 × Nein, 2 × Nicht zutreffend

TECHNISCHER TEST — Robustheitstest

Original- und gestörter (perturbierter) Datensatz: Der Test erzeugt einen gestörten Datensatz mit dem Ziel, abweichende Vorhersagen zu provozieren. Ein robustes Modell erzielt für beide Datensätze ähnliche Genauigkeit.

Was das bedeutet: Original- und gestörter Datensatz erzielten eine Genauigkeit von 50 % bzw. 26 % — ein Rückgang von 24,08 %. Das Modell ist möglicherweise nicht robust.

Empfehlung(en): Da der Rückgang groß ist, können Methoden wie das Hinzufügen von Rauschen und Datenaugmentierung während des Trainings erwogen werden. Zusätzlich kann die gesamte Bereitstellung überdacht und der Datensatz neu bewertet werden.

04 / FAIRNESS / KEINE UNBEABSICHTIGTE DISKRIMINIERUNG

Sicherstellen, dass der Einsatz von KI nicht unbeabsichtigt diskriminiert

Das Prinzip der Fairness wurde anhand von 10 Prozessprüfungen und einem technischen Test bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zur Fairness.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Prozesse zum Testen auf potenzielle Verzerrungen während des gesamten Lebenszyklus einführen
- Strategie zur Auswahl geeigneter Fairness-Kennzahlen etablieren
- Sensible Merkmale für die Organisation definieren
- Prozess zur Identifizierung von Teilpopulationen für faire Ergebnisse etablieren
- Mechanismus zur Meldung von Verzerrungs-/Diskriminierungsproblemen einführen
- Geeignete Mechanismen zur Sicherstellung von Fairness einführen

Was das bedeutet:

Das Unternehmen läuft Gefahr, Ursachen von Verzerrungen nicht überwachen und über den Lebenszyklus hinweg beheben zu können — mit möglichen diskriminierenden Ergebnissen und Vertrauensverlust.

Empfehlung(en):

Prozesse zur Identifizierung und zum Testen potenzieller Verzerrungen einführen; Mechanismen zur Minderung sowie Dokumentation möglicher datensatzbedingter Einschränkungen etablieren.

Ergebnisübersicht: 4 × Ja, 3 × Nein, 3 × Nicht zutreffend

TECHNISCHER TEST — Fairness-Test (ausgewähltes Merkmal: Geschlecht)

Der Test zeigt, wie korrekt das Modell das ausgewählte sensible Merkmal vorhergesagt hat. Ausgewählte Kennzahlen: False Discovery Rate und Negative Predictive Value Parity (im Idealfall nahe 0 %).

- False Discovery Rate — Klasse 0: Parität 0,04; Klasse 1: Parität 0,01
- Negative Predictive Value Parity — Klasse 0: Parität 0,006; Klasse 1: Parität 0,026

Was das bedeutet: Die Ergebnisse helfen zu verstehen, ob das Modell über demografische Gruppen hinweg fair vorhersagt.

Empfehlungen: Kennzahlen mit relevanten Stakeholdern überprüfen. Ist die Parität vernachlässigbar, keine weitere Maßnahme nötig. Andernfalls: (1) Datensatz auf inhärente Verzerrungen prüfen, (2) Modellparameter/Algorithmen überprüfen, (3) Post-Processing-Minderungsalgorithmen anwenden (siehe: „A Reductions Approach to Fair Classification“).

DATA GOVERNANCE

Das Prinzip der Data Governance wurde anhand von 4 Prozessprüfungen bewertet.

Zusammenfassende Begründung

Das Unternehmen hat keinen Grund angegeben.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Maßnahmen zum Verständnis der Datenherkunft einführen
- Sicherstellen, dass Datenpraktiken regulatorischen Anforderungen/Branchenstandards entsprechen

Was das bedeutet:

Es besteht das Risiko von Datenqualitätsproblemen, Verzerrungsproblemen, Datensicherheitsrisiken und Compliance-Problemen mit Datenschutzvorschriften.

Empfehlung(en):

Alle testbaren Kriterien umsetzen; Gründe für Nichtumsetzung überprüfen und Data-Governance-Richtlinie sowie relevante Standards erwägen.

Ergebnisübersicht: 2 × Ja, 1 × Nein, 1 × Nicht zutreffend

05 / MANAGEMENT UND AUFSICHT DES KI-SYSTEMS (ACCOUNTABILITY)

Sicherstellen menschlicher Verantwortlichkeit und Kontrolle

Das Prinzip der Accountability wurde anhand von 8 Prozessprüfungen bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zur Accountability.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Klare interne Governance-Mechanismen für Rollen/Verantwortlichkeiten etablieren
- Richtlinienmechanismus für Zugriffsrechte/Berechtigungen definieren
- Strategie zur unabhängigen Aufsicht über Entwicklung/Bereitstellung etablieren
- Bei Drittanbieter-Blackbox-Modellen Eignung/Grenzen bewerten

Was das bedeutet:

Die derzeitige Organisationsstruktur bietet möglicherweise keine ausreichende Verantwortlichkeit und Aufsicht über das KI-System.

Empfehlung(en):

Organisationsstruktur und internen Governance-Mechanismus überprüfen, um klare Verantwortlichkeit sicherzustellen.

Ergebnisübersicht: 3 × Ja, 3 × Nein, 2 × Nicht zutreffend

MENSCHLICHES HANDELN & AUFSICHT

Das Prinzip Human Agency & Oversight wurde anhand von 8 Prozessprüfungen bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zu Human Agency & Oversight.

Das Unternehmen hat folgende testbare Kriterien nicht vollständig umgesetzt:

- Sicherstellen, dass Beteiligte angemessen geschult und ausgestattet sind für ordnungsgemäße Aufsicht
- Spezifische Aufsichts-/Kontrollmaßnahmen für selbstlernende/autonome Systeme sicherstellen
- Überprüfungsprozess vor Produktivsetzung mit zugänglicher Visualisierung einführen
- Sicherstellen, dass zuständige Parteien den Nutzen für Menschen in Entscheidungsprozessen berücksichtigt haben

Was das bedeutet:

Es fehlen möglicherweise angemessene Aufsichts-/Kontrollmaßnahmen für menschliches Eingreifen bei Systemversagen — mit erhöhtem Schadensrisiko.

Empfehlung(en):

Aufsichts-/Kontrollmaßnahmen überprüfen, damit ein Mensch das System rechtzeitig verbessern oder außer Kraft setzen kann.

Ergebnisübersicht: 3 × Ja, 3 × Nein, 2 × Nicht zutreffend

INKLUSIVES WACHSTUM, GESELLSCHAFTLICHES & ÖKOLOGISCHES WOHLERGEHEN

Das Prinzip wurde anhand von 1 Prozessprüfung bewertet.

Zusammenfassende Begründung

Dies ist eine Beispiel-Zusammenfassung für die Prozessprüfungen zu Inclusive Growth, Societal & Environmental Well-being.

Was das bedeutet:

Das Unternehmen hat die weiterreichenden Implikationen des KI-Systems berücksichtigt — seine Auswirkungen auf Gesellschaft und Umwelt über funktionale und kommerzielle Ziele hinaus.

Empfehlung(en):

Keine weitere Empfehlung.

Ergebnisübersicht: 1 × Ja

TRANSPARENZ

Kriterium 1.1 Den Endnutzern die notwendigen Informationen zur Nutzung ihrer personenbezogenen Daten bereitstellen, um sicherzustellen, dass diese in fairer und transparenter Weise verarbeitet werden

1.1.1 – Prozess

Ausrichtung an (1) den Advisory Guidelines der PDPC zu den Kernkonzepten der PDPA; (2) dem Guide to Accountability; und (3) dem Guide to Data Protection Impact Assessments

Prozessprüfung

Dokumentarischer Nachweis einer internen Richtlinie, die die Ausrichtung an bestehenden Datenschutzgesetzen und -vorschriften vorschreibt, einschließlich: (in Singapur) - PDPC Advisory Guidelines on Key Concepts in the PDPA; - Guide to Accountability; und - Guide to Data Protection Impact Assessments. (außerhalb Singapurs) - anwendbare Datenschutzgesetze/-vorschriften

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (z. B. Richtliniendokument)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

1.1.2 – Prozess

Veröffentlichung einer Datenschutzerklärung auf der Website der Organisation, um Informationen über die Nutzung personenbezogener Daten im KI-System bereitzustellen (z. B. Datenpraktiken und Entscheidungsprozesse). Der allgemeine Offenlegungshinweis könnte umfassen: – Offenlegung der Einbindung Dritter – Definition von Dateneigentum und -portabilität – Darstellung des Datenflusses und Identifizierung etwaiger Datenlecks – Angabe der Standards, mit denen das Unternehmen konform ist

Prozessprüfung

Dokumentarischer Nachweis einer veröffentlichten Datenschutzerklärung, die Informationen über die Nutzung personenbezogener Daten im KI-System bereitstellt, einschließlich: – Offenlegung der Einbindung Dritter; – Definition von Dateneigentum und -portabilität; – Darstellung des Datenflusses und Identifizierung etwaiger Datenlecks; und – Angabe der Standards, mit denen das Unternehmen konform ist

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 1.2 Wo möglich (z. B. ohne geistiges Eigentum, Sicherheit oder Systemintegrität zu gefährden), geeignete Zeitpunkte im KI-Lebenszyklus identifizieren, um Endnutzer und/oder Betroffene in zugänglicher Weise über Zweck, Kriterien, Einschränkungen und Risiken der vom KI-System erzeugten Entscheidung(en) zu informieren

1.2.1 – Prozess

Entwicklung einer internen Richtlinie zur Kommunikation mit Verbrauchern, die die Grundsätze der Transparenz darlegt, z. B. Definition von Zweck und Kontext der Kommunikation

Prozessprüfung

Dokumentarischer Nachweis einer internen Richtlinie zur Kommunikation mit Verbrauchern, die die Grundsätze der Transparenz darlegt

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (z. B. Richtliniendokument)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

1.2.2 – Prozess

Relevante Stakeholder darüber informieren, dass KI in den Produkten und/oder Dienstleistungen eingesetzt wird

Prozessprüfung

Dokumentarischer Nachweis der Kommunikation an relevante Stakeholder, dass KI in den Produkten und/oder Dienstleistungen der Organisation eingesetzt wird

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

1.2.3 – Prozess

Bei Entscheidungen des KI-Systems den Endnutzern nach Möglichkeit die Faktoren mitteilen, die zur Entscheidung geführt haben, z. B. „Ihnen wird dieses Produkt gezeigt, weil Sie diesen Artikel gekauft haben."

Prozessprüfung

Dokumentarischer Nachweis der Kommunikation an Endnutzer über die Faktoren, die zu Entscheidungen der KI-Systeme geführt haben

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

1.2.4 – Prozess

Endnutzer bereits in frühen Phasen der Entwicklung des KI-Systems konsultieren, um zu vermitteln, wie die Technologie eingesetzt und bereitgestellt wird

Prozessprüfung

Dokumentarischer Nachweis der Kommunikation mit Endnutzern in frühen Entwicklungsphasen hinsichtlich Einsatz und Bereitstellung der Technologie

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

1.2.5 – Prozess

Relevante Informationen zu Genauigkeit, beabsichtigten Anwendungsfällen und Einschränkungen des KI-Systems, einschließlich der Risikobewertung, den Endnutzern zugänglich machen

Prozessprüfung

Dokumentarischer Nachweis der Kommunikation mit Endnutzern über das KI-System, einschließlich (soweit zutreffend): Genauigkeit, Konfidenzwerte, beabsichtigte Anwendungsfälle, Einschränkungen und Risikobewertung

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 1.3 Informationen bereitstellen, um Endnutzer in zugänglicher Weise zur ordnungsgemäßen Nutzung des KI-Systems anzuleiten

1.3.1 – Prozess

Informationen wie Zweck, beabsichtigte Nutzung und beabsichtigte Reaktion des KI-Systems für Endnutzer bereitstellen

Prozessprüfung

Dokumentarischer Nachweis der Kommunikation mit Endnutzern über die beabsichtigte Nutzung und Reaktion des KI-Systems (z. B. Model Card und Data Card)

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

ERKLÄRBARKEIT

Kriterium 2.1 Eine Präferenz für die Entwicklung von KI-Modellen zeigen, die ihre Entscheidungen erklären können oder standardmäßig interpretierbar sind

2.1.1 – Prozess

Bei Wahl eines weniger erklärbaren Modellierungsansatzes die Begründung, Risikobewertungen und Kompromisse des KI-Modells dokumentieren

Prozessprüfung

Dokumentarischer Nachweis der Erwägungen bei der Wahl des KI-Modells: Begründung, Risikobewertung und Kompromisse

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

WIEDERHOLBARKEIT / REPRODUZIERBARKEIT

Kriterium 3.1 Methoden einführen, um die Herkunft (Provenienz) des KI-Modells zu dokumentieren, einschließlich der verschiedenen Versionen, Konfigurationen, Datentransformationen und des zugrunde liegenden Quellcodes

3.1.1 – Prozess

Versionskontrolle des Quellcodes und der zur Modellentwicklung verwendeten Frameworks implementieren. Für jede Modellversion Codeversion, Parameter, Hyperparameter und Quelldaten nachverfolgen

Prozessprüfung

Dokumentarischer Nachweis der Versionskontrolle von Quellcode und Frameworks, einschließlich Erwägungen zum erforderlichen Umfang der Versionshistorie

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.2 Maßnahmen einführen, um die Datenqualität im Zeitverlauf sicherzustellen

3.2.1 – Prozess

Überprüfung der Qualität der im KI-System verwendeten Daten hinsichtlich Genauigkeit, Vollständigkeit, Glaubwürdigkeit, Aktualität, Relevanz, Integrität und Nutzbarkeit sowie Bereitstellung von Verteilungsanalysen

Prozessprüfung

Dokumentarischer Nachweis, dass die gebotene Sorgfalt zur Sicherstellung der Datenqualität angewendet wurde (z. B. Validierungsprüfungen, Fehleridentifikation, Rollenzuweisung in der Datenpipeline, Review-Prozesse, Unit-Tests, periodische Überprüfung, kontinuierliche Qualitätsbewertung)

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.3 Maßnahmen einführen, um die Herkunft (Lineage) der Daten zu verstehen, einschließlich Kenntnis darüber, woher die Daten ursprünglich stammen, wie sie erhoben, kuratiert und im Zeitverlauf bewegt wurden

3.3.1 – Prozess

Führung eines Datenherkunftsprotokolls zur Beurteilung der Datenqualität anhand ihrer Herkunft und Transformation

Prozessprüfung

Dokumentarischer Nachweis eines Datenherkunftsprotokolls (Datenquelle, Kennzeichnung, Bias-Bewertung, Transformation, Risikomanagement)

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.4 Die vom KI-System zur Erzeugung einer bestimmten Entscheidung oder Empfehlung verwendeten Daten nachverfolgen

3.4.1 – Prozess

Die zum Training verwendeten Daten sowie die Erzeugung von Inferenzergebnissen klar protokollieren und erfassen

Prozessprüfung

Dokumentarischer Nachweis der verwendeten Daten (Trainingsdaten und Inferenzdaten)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.5 Das KI-Modell oder die Regeln nachverfolgen, die zu der Entscheidung/den Empfehlungen des KI-Systems geführt haben

3.5.1 – Prozess

Die Inferenzergebnisse des Modells mit dem zugrunde liegenden Modell und Quellcode verknüpfen

Prozessprüfung

Dokumentarischer Nachweis der Verknüpfung der Inferenzergebnisse mit dem zugrunde liegenden Modell und Quellcode

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.6 Angemessene Protokollierungspraktiken einführen, um die Entscheidung(en)/Empfehlung(en) des KI-Systems zu erfassen

3.6.1 – Prozess

Alle Eingaben und Inferenzausgaben des Modells protokollieren und für einen angemessenen Zeitraum speichern

Prozessprüfung

Dokumentarischer Nachweis von Protokolldaten zu Entscheidungen/Empfehlungen des KI-Systems, ggf. inkl. menschlicher Akzeptanz/Ablehnung

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.7 Den Trainingsprozess für jedes evaluierte Modell reproduzieren (außer Daten)

3.7.1 – Prozess

Versionskontrolle von Modellartefakten durch Verknüpfung mit Code-, Abhängigkeits- und Parameterversion

Prozessprüfung

Dokumentarischer Nachweis der Versionskontrolle von Modellartefakten (Codeversion, Abhängigkeiten, Trainingsparameter)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.8 Beurteilung der Wiederholbarkeit durch Überprüfung, ob das Modell bei gleicher Eingabe dasselbe Ergebnis liefert (nicht relevant bei Retraining)

3.8.1 – Prozess

Mehrere Inferenzen berechnen; bei normalverteilten Daten akzeptierte Grenzen von +/-1,96-facher Standardabweichung anwenden

Prozessprüfung

Dokumentarischer Nachweis der Bewertung, ob das Modell bei gleicher Eingabe dasselbe Ergebnis liefert

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.9 Den Prozess zur Modellentwicklung definieren und bewerten

3.9.1 – Prozess

Eine Kombination aus technischen und geschäftlichen Kennzahlen identifizieren, anhand derer KI-Modelle bewertet werden

Prozessprüfung

Dokumentarischer Nachweis der Bewertungskennzahlen (technisch und/oder geschäftlich)

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

3.9.2 – Prozess

Experimente nachverfolgen (z. B. Hyperparameter, Modellleistung) zur Entwicklung von Konkurrenzmodellen und Begründung dokumentieren, wie das endgültige Modell zustande kam

Prozessprüfung

Dokumentarischer Nachweis des Entwicklungsprozesses (Hyperparameter, Modellleistung, Begründung, Ableitung des finalen Modells)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.10 Eine Strategie zur Reproduktion der im Trainingsprozess verwendeten Eingabedaten für jedes Modell etablieren

3.10.1 – Prozess

Versionskontrolle der Trainings-Eingabedaten, wo möglich; sonst Nachverfolgung der Transformationsschritte, vorzugsweise als DAG

Prozessprüfung

Dokumentarischer Nachweis einer Strategie zur Reproduktion der Eingabedaten (Datenbereinigung, Versionskontrolle, DAG)

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.11 Eine Strategie etablieren, um sicherzustellen, dass Annahmen auch bei nachfolgendem Retraining mit neuen Eingabedaten weiterhin gültig sind

3.11.1 – Prozess

Statistische Verteilung von Eingabemerkmalen und Ausgabeergebnissen erfassen, um Abweichungen beim Retraining zu erkennen

Prozessprüfung

Dokumentarischer Nachweis der Strategie (z. B. K-L-Divergenz, K-S-Test, gleitender Durchschnitt)

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.12 Ausgaben des KI-Systems reproduzieren

3.12.1 – Prozess

Audit-Trail protokollieren: wann und wie jedes Modell bereitgestellt wurde, verwendeter Code, Test-/Validierungsdaten, Version des Artefakts

Prozessprüfung

Dokumentarischer Nachweis früherer Ausgaben des bereitgestellten KI-Systems

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.13 Bei Verwendung eines Blackbox- oder Drittanbietermodells die Genauigkeitsangaben des Anbieters bewerten

3.13.1 – Prozess

Testdatensatz kuratieren und auf das Modell anwenden, um die Leistung zu überprüfen

Prozessprüfung

Dokumentarischer Nachweis der Bewertung der Genauigkeitsangaben des Anbieters

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 3.14 Eine Strategie etablieren, um die Qualität der Ausgaben kontinuierlich zu bewerten und sicherzustellen, dass Betriebsbedingungen mit der ursprünglichen Entwicklungsthese übereinstimmen

3.14.1 – Prozess

Kontinuierliche Überwachung und regelmäßige Validierung nach Livegang, inkl. Modell- und Anwendungsleistung

Prozessprüfung

Dokumentarischer Nachweis kontinuierlicher Überwachung (Schwellenwert-Benachrichtigungen, Modell- und Anwendungsleistung)

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

SICHERHEIT (SAFETY)

Kriterium 4.1 Eine Wesentlichkeitsbewertung (Materiality Assessment) für zentrale Stakeholder durchführen

4.1.1 – Prozess

Wesentlichkeitsbewertung ausfüllen und zuständigen Parteien vorlegen; Begründungen und Governance-/Kontrollmaßnahmen dokumentieren

Prozessprüfung

Dokumentarischer Nachweis der Wesentlichkeitsbewertung (Schadenswahrscheinlichkeit, -schwere, Bedrohungswahrscheinlichkeit, menschliche Beteiligung, Modellkomplexität, Stakeholder-Auswirkung, Transparenzgrad, Vertrauensauswirkung)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** 1) Internes Verfahrenshandbuch 2) Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 4.2 Risiken, Risikokennzahlen und Risikostufen des KI-Systems für jeden Anwendungsfall bewerten, einschließlich Abhängigkeit kritischer Entscheidungen von stabilem Verhalten

4.2.1 – Prozess

Beabsichtigte Anwendungsfälle, Fähigkeiten und Einschränkungen dokumentieren (z. B. Model Cards), gespeichert mit dem Modellartefakt

Prozessprüfung

Dokumentarischer Nachweis der Risikobewertung für spezifische Anwendungsfälle

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 4.3 Einen Prozess einführen, um Risiken kontinuierlich zu bewerten, zu messen und zu überwachen, einschließlich Identifizierung neuer Risiken nach der Bereitstellung

4.3.1 – Prozess

Einen Prüfer benennen, der mit dem Anwendungsfall vertraut ist, zur Überprüfung nach Bereitstellung

Prozessprüfung

Dokumentarischer Nachweis eines Prozesses zur kontinuierlichen Risikoüberwachung

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (z. B. Protokoll, Register oder Datenbank)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 4.4 Bewerten, ob das KI-System versagen könnte, unter Berücksichtigung von Eingabemerkmalen und vorhergesagten Ergebnissen zur Kommunikationsunterstützung

4.4.1 – Prozess

KI-Modelle mit Konfidenzwert verwenden; Mechanismen zur Ausreißererkennung implementieren

Prozessprüfung

Dokumentarischer Nachweis der Bewertung möglichen Versagens des KI-Systems

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 4.5 Fehlertoleranz planen, z. B. durch ein dupliziertes oder paralleles System

4.5.1 – Prozess

Bereitstellungsstrategien wie Blue-Green- und Canary-Deployments implementieren

Prozessprüfung

Dokumentarischer Nachweis von Bereitstellungsstrategien und Failover-Plan

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

4.5.2 – Prozess

Backup-Modellserver im Blue-Green-Deployment-Modus vorhalten

Prozessprüfung

Dokumentarischer Nachweis der Vorhaltung des Backup-Modellservers

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

4.5.3 – Prozess

KI-Modelle mit Konfidenzwert verwenden; Fallback auf Backup-Modellserver oder Standardverhalten ermöglichen

Prozessprüfung

Dokumentarischer Nachweis der Nutzung von Konfidenzwerten und Fallback-Mechanismen

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

4.5.4 – Prozess

Feedback-Loop schließen durch Retraining mit im Produktivbetrieb gewonnener Ground Truth

Prozessprüfung

Dokumentarischer Nachweis der Schließung des Feedback-Loops

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 4.6 Restrisiken identifizieren, die nicht gemindert werden können, und die Risikotoleranz der Organisation dafür bewerten

4.6.1 – Prozess

Bewertung des Restrisikos dokumentieren und Gründe für Toleranzniveau angeben

Prozessprüfung

Dokumentarischer Nachweis der Bewertung des Restrisikos und der Toleranzgründe

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

SICHERHEIT (SECURITY)

Kriterium 5.1 Teamkompetenz sicherstellen

5.1.1 – Prozess

Sicherstellen, dass Teammitglieder über Bedrohungen, Schwachstellen, Auswirkungen und Minderungsmaßnahmen informiert sind und ihr Wissen aktuell halten

Prozessprüfung

Dokumentarischer Nachweis relevanter Sicherheitsschulungen (Schulungs-/Anwesenheitsnachweise, Bewertungen, Zertifizierungen, Feedback)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 5.2 Sicherheitsrisikobewertung zu Beginn der Entwicklung des KI-Systems durchführen

5.2.1 – Prozess

Angemessene Risikobewertung gemäß Branchenstandards durchführen; Risikominderungsschritte unternehmen

Prozessprüfung

Dokumentarischer Nachweis der Risikobewertung gemäß Standards (z. B. NIST AI RMF, UK NCSC, OWASP SSDLC, CIA-Triade)

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation (z. B. Risikobewertung)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 5.3 Sicherheitsmaßnahmen während Verifizierung und Validierung der Entwicklung einführen

5.3.1 – Prozess

Sicherstellen, dass Integrität von Daten/Modellen gegeben ist und eine Nachweiskette besteht

Prozessprüfung

Dokumentarischer Nachweis vertrauenswürdiger Datenquellen bzw. Begründung für synthetische/begrenzte Daten

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

5.3.2 – Prozess

Integrität erworbener Datensätze durch robuste Validierung/Verifizierung bewerten

Prozessprüfung

Dokumentarischer Nachweis der Bewertung (Mehrfachkennzeichnung, vertrauenswürdige Anbieter, Audits)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 5.4 Sicherheitsmaßnahmen während Design und Entwicklung einführen

5.4.1 – Prozess

Entwicklungsumgebung absichern, inkl. vertrauenswürdiger Zugriffskontrollen

Prozessprüfung

Dokumentarischer Nachweis abgesicherter Entwicklungsumgebung (CVE-Monitoring, sichere Firmware, Least Privilege, Logging)

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation (Zugriffskontroll-Dokument)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

5.4.2 – Prozess

Digitale Vermögenswerte absichern, inkl. ruhender und übertragener Daten

Prozessprüfung

Dokumentarischer Nachweis der Absicherung (z. B. ISO 27001)

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Asset-Management-Dokument)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

5.4.3 – Prozess

Änderungen an Modell/Daten in konsistentem, menschenlesbarem Format nachverfolgen und speichern

Prozessprüfung

Dokumentarischer Nachweis der Nachverfolgung (Nutzeränderungen, Review, Rollback)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (Asset-Management-Dokument)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

5.4.4 – Prozess

Maßnahmen gegen Angriffe auf den Datensatz implementieren (z. B. Poisoning); Datenbereinigung, Anreicherung, sichere Speicherung, Validierung

Prozessprüfung

Dokumentarischer Nachweis der Minderungsmaßnahmen

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 5.5 Sicherheitsmaßnahmen während Bereitstellung und Überwachung einführen

5.5.1 – Prozess

Maßnahmen gegen Inferenz-/Extraktionsangriffe implementieren

Prozessprüfung

Dokumentarischer Nachweis (API-Überwachung, Ratenbegrenzung, Authentifizierung)

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Protokoll, Register, Datenbank)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

5.5.2 – Prozess

Warnsystem für anomales Verhalten implementieren (z. B. unbefugter Zugriff)

Prozessprüfung

Dokumentarischer Nachweis (Logging, Meldung an Stakeholder/Behörden, Human-in-the-Loop)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

5.5.3 – Prozess

Prozess zur Offenlegung von Schwachstellen entwickeln

Prozessprüfung

Dokumentarischer Nachweis eines Vulnerability-Disclosure-Prozesses (z. B. UK NCSC Toolkit)

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 5.6 Sicherheitsmaßnahmen für kontinuierliches/Online-Lernmodell einführen

5.6.1 – Prozess

Risiken kontinuierlichen Lernens berücksichtigen (Poisoning, Drift); Rechtfertigung mit Risikominderungen prüfen

Prozessprüfung

Dokumentarischer Nachweis interner Genehmigung von Leistungszielen vor Produktivsetzung

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Risikomanagement-Dokument)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

5.6.2 – Prozess

Sicherstellen, dass genehmigte Leistungsziele vor Produktivsetzung erreicht werden

Prozessprüfung

Dokumentarischer Nachweis der Zielerreichung vor Produktivsetzung

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (Roadmap)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 5.7 Sicherheitsmaßnahmen für Ende der Lebensdauer des KI-Systems einführen

5.7.1 – Prozess

Ordnungsgemäße, sichere Entsorgung/Vernichtung von Daten und Modell gemäß Standards sicherstellen

Prozessprüfung

Dokumentarischer Nachweis ordnungsgemäßer Entsorgung

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

ROBUSTHEIT

Kriterium 6.1 Maßnahmen zur Sicherstellung der Datenqualität einführen

6.1.1 – Prozess

Sicherstellen, dass Daten aktuell, vollständig und repräsentativ sind; Metadaten protokollieren; Produktions- vs. Trainingsdaten überwachen

Prozessprüfung

Nachweis von Leistungskennzahlen, Konfidenzwerten und Datenqualität

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 6.2 Faktoren geringer Genauigkeit überprüfen und mögliche kritische/adversarielle Folgen bewerten

6.2.1 – Prozess

Beabsichtigte Anwendungsfälle, Risiken und Einschränkungen dokumentieren (z. B. Model Cards)

Prozessprüfung

Dokumentarischer Nachweis in Model Cards

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 6.3 Berücksichtigen, ob der Betrieb des KI-Systems die Trainingsannahmen ungültig machen kann (Feedback-Loops, Nutzeranpassung, adversarielle Angriffe)

6.3.1 – Prozess

Beabsichtigte Anwendungsfälle, Risiken, Einschränkungen dokumentieren

Prozessprüfung

Dokumentarischer Nachweis in Model Cards

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 6.4 Mechanismus einführen, um zu bewerten, wann eine erneute Überprüfung der technischen Robustheit gerechtfertigt ist

6.4.1 – Prozess

Überprüfungsprozess für Änderungen in Code, Eingabe- und Ausgabedaten implementieren

Prozessprüfung

Dokumentarischer Nachweis des Überprüfungsmechanismus

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 6.5 Strategie zur Überwachung und Minderung von Blackbox-Angriffen auf live geschaltete Systeme etablieren

6.5.1 – Prozess

Methoden zur Minderung bekannter adversarieller Angriffe zur Trainingszeit implementieren

Prozessprüfung

Dokumentarischer Nachweis der Implementierung/Entscheidung zu Minderungsmethoden

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

6.5.2 – Prozess

Anfragen an das live geschaltete System überwachen (Häufigkeit, Merkmalsverteilung)

Prozessprüfung

Dokumentarischer Nachweis der Überwachung verdächtiger Nutzung

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

6.5.3 – Prozess

Maßnahmen gegen Nutzer mit verdächtigen Aktivitäten ergreifen (Markierung, Begrenzung, Sperrung)

Prozessprüfung

Dokumentarischer Nachweis ergriffener Maßnahmen

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

FAIRNESS

Kriterium 7.1 Fairness innerhalb einer Gruppe bewerten (individuelle Fairness)

7.1.1 – Prozess

Kontrafaktische Fairness-Bewertung anwenden

Prozessprüfung

Dokumentarischer Nachweis der kontrafaktischen Fairness-Bewertung

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.2 Prozesse zum Testen auf potenzielle Verzerrungen während des gesamten Lebenszyklus einführen

7.2.1 – Prozess

Änderungen der Fairness-Kennzahlenwerte im Lebenszyklus überwachen

Prozessprüfung

Dokumentarischer Nachweis implementierter Testprozesse

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.3 Strategie zur Auswahl geeigneter Fairness-Kennzahlen etablieren

7.3.1 – Prozess

Fairness-Entscheidungsbaum (z. B. AI Verify, Aequitas) zur Auswahl der Kennzahl(en) erwägen

Prozessprüfung

Dokumentarischer Nachweis der Auswahlstrategie (Equal Parity, Disparate Impact, u. a.)

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.4 Sensible Merkmale für die Organisation definieren, konsistent mit Gesetzgebung und Unternehmenswerten

7.4.1 – Prozess

Sensible Merkmale und privilegierte/unprivilegierte Gruppen identifizieren

Prozessprüfung

Dokumentarischer Nachweis der Identifizierung sensibler Merkmale

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

7.4.2 – Prozess

Betroffene Gemeinschaften zur korrekten Definition von Fairness konsultieren

Prozessprüfung

Dokumentarischer Nachweis durchgeführter Konsultationen

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.5 Prozess zur Identifizierung von Teilpopulationen etablieren, zwischen denen faire Ergebnisse erzielt werden sollen

7.5.1 – Prozess

Partitionierung anhand sensibler Merkmale definieren, die nicht Trainingsgrundlage, aber Fairness-Bewertungsgrundlage sind

Prozessprüfung

Dokumentarischer Nachweis der Etablierung dieses Prozesses

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.6 Strategie etablieren, um die Repräsentativität der Trainingsdaten für die Endnutzerpopulation zu prüfen

7.6.1 – Prozess

Explorative Datenanalyse durchführen; unterrepräsentierte Gruppen neu abtasten oder mehr Daten sammeln

Prozessprüfung

Dokumentarischer Nachweis der Repräsentativitätsprüfung

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests
Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.7 Mechanismus zur Meldung von Verzerrungs-, Diskriminierungs- oder Leistungsproblemen einführen

7.7.1 – Prozess

Schwellenwertverletzungen von Fairness-Kennzahlen und tatsächliche Schäden überwachen

Prozessprüfung

Dokumentarischer Nachweis der Überwachung und des Feedback-Prozesses

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests
Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.8 Geeignete Mechanismen zur Sicherstellung von Fairness einführen

7.8.1 – Prozess

Kennzahlen für aktuelle Daten des bereitgestellten Modells fortlaufend überwachen

Prozessprüfung

Dokumentarischer Nachweis der fortlaufenden Überwachung

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests
Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 7.9 Risiko von Verzerrungen durch Datensatzzusammensetzung mittels Anpassungen an Minderheiten-Stichproben adressieren

7.9.1 – Prozess

Unausgewogene Trainingsdatensätze behandeln (Oversampling, Undersampling, SMOTE)

Prozessprüfung

Dokumentarischer Nachweis der Behandlung unausgewogener Datensätze

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests
Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

DATA GOVERNANCE

Kriterium 8.1 Maßnahmen einführen, um die Datenqualität im Zeitverlauf sicherzustellen

8.1.1 – Prozess

Überprüfung der Datenqualität hinsichtlich Genauigkeit, Vollständigkeit, Glaubwürdigkeit, Aktualität, Relevanz, Integrität und Nutzbarkeit

Prozessprüfung

Dokumentarischer Nachweis angewandter Sorgfalt zur Sicherstellung der Datenqualität

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation
Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 8.2 Maßnahmen einführen, um die Herkunft (Lineage) der Daten zu verstehen

8.2.1 – Prozess

Datenherkunftsprotokoll führen (Erhebung, Kennzeichnung, Bias-Bewertung, Transformation)

Prozessprüfung

Dokumentarischer Nachweis eines Datenherkunftsprotokolls

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 8.3 Sicherstellen, dass Datenpraktiken den regulatorischen Anforderungen oder Branchenstandards entsprechen

8.3.1 – Prozess

Bewertung gemäß regulatorischen Anforderungen/Branchenstandards durchführen (z. B. PDPA, EU Data Governance Act, ISO, NIST)

Prozessprüfung

Dokumentarischer Nachweis der Bewertung gemäß Standards

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** 1) Interne Dokumentation; 2) Bewertungsdokumentation/Zertifizierung

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 8.4 Teamkompetenz im Bereich Data Governance sicherstellen

8.4.1 – Prozess

Sicherstellen, dass Teammitglieder über Rollen und Verantwortlichkeiten in Data Governance informiert sind

Prozessprüfung

Dokumentarischer Nachweis relevanter Schulungen (Nachweise, Bewertungen, Zertifizierungen)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

ACCOUNTABILITY

Kriterium 9.1 Klare interne Governance-Mechanismen für Rollen und Verantwortlichkeiten etablieren

9.1.1 – Prozess

Bestehende Strukturen anpassen oder neue implementieren (z. B. Three-Lines-of-Defense-Modell)

Prozessprüfung

Dokumentarischer Nachweis der Anpassung/Neueinführung von Strukturen

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

9.1.2 – Prozess

KI-Governance-Ausschuss mit Vertretern aus Data Science, Technologie, Risiko und Produkt etablieren

Prozessprüfung

Dokumentarischer Nachweis der Etablierung eines KI-Governance-Ausschusses

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

9.1.3 – Prozess

Prozess zur Meldung von Handlungen/Entscheidungen, die das Ergebnis beeinflussen, sowie Reaktionsprozess einführen

Prozessprüfung

Dokumentarischer Nachweis von Rollen, Verantwortlichkeiten und Prozessen

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 9.2 Prozess bzw. Governance-by-Design-Technologie zur Auditierbarkeit über den Lebenszyklus etablieren

9.2.1 – Prozess

Versionskontrolle, Datenversionierung und Audit-Trail des Bereitstellungsverlaufs handhaben

Prozessprüfung

Dokumentarischer Nachweis der Etablierung des Prozesses/der Technologie

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 9.3 Richtlinienmechanismus für Zugriffsrechte und Berechtigungen definieren

9.3.1 – Prozess

Feingranulare Zugriffskontrolle für Code, Daten, Ausführungsumgebungen und administrative Funktionen implementieren

Prozessprüfung

Dokumentarischer Nachweis der Implementierung feingranularer Zugriffskontrolle

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 9.4 Strategie zur Aufrechterhaltung unabhängiger Aufsicht über Entwicklung und Bereitstellung etablieren

9.4.1 – Prozess

Prüfer sollten sich von Trainings-/Bereitstellungspersonal unterscheiden (Ausnahmen möglich)

Prozessprüfung

Dokumentarischer Nachweis der Strategie zur unabhängigen Aufsicht

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Protokoll, Register, Datenbank)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 9.5 Bei Drittanbieter-Blackbox-Modellen Eignung und Grenzen für den Anwendungsfall bewerten

9.5.1 – Prozess

Notwendigkeit von Drittanbietermodellen bewerten

Prozessprüfung

Dokumentarischer Nachweis der Bewertung der Notwendigkeit

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

9.5.2 – Prozess

Verständnis der Modellerstellung nachweisen (Trainingsdaten, Bewertungsmethoden, Schwächen)

Prozessprüfung

Dokumentarischer Nachweis der unternommenen Bemühungen

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

MENSCHLICHES HANDELN & AUFSICHT

Kriterium 10.1 Sicherstellen, dass Beteiligte angemessen geschult und mit Werkzeugen für ordnungsgemäße Aufsicht ausgestattet sind

10.1.1 – Prozess

Geführten Ablauf zur Dokumentation wichtiger Informationen und Entscheidungsprozesse einführen

Prozessprüfung

Dokumentarischer Nachweis eines geführten Dokumentationsablaufs

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

10.1.2 – Prozess

Datenmanagementsystem für unterschiedliche Nutzerrollen implementieren

Prozessprüfung

Dokumentarischer Nachweis des Datenmanagementsystems

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch, Protokoll, Register, Datenbank)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 10.2 Spezifische Aufsichts- und Kontrollmaßnahmen für selbstlernende/autonome Systeme sicherstellen

10.2.1 – Prozess

Rolle des Menschen bei Aufsicht/Kontrolle definieren (Human-in/out/over-the-Loop)

Prozessprüfung

Dokumentarischer Nachweis der Definition der menschlichen Rolle

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

10.2.2 – Prozess

System so gestalten, dass unsichere Entscheidungen markiert und einem Menschen vorgelegt werden

Prozessprüfung

Dokumentarischer Nachweis der Designberücksichtigung

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

10.2.3 – Prozess

Mechanismen zur Ausreißererkennung bei Eingaben implementieren

Prozessprüfung

Dokumentarischer Nachweis der Implementierung

Abgeschlossen: Nein **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 10.3 Überprüfungsprozess vor Produktivsetzung einführen, mit für Entscheidungsträger zugänglicher Visualisierung

10.3.1 – Prozess

Systematischen Überprüfungsprozess für Leistungs-, Erklärbarkeits- und Fairness-Kennzahlen implementieren

Prozessprüfung

Dokumentarischer Nachweis des Überprüfungsprozesses

Abgeschlossen: Nicht zutreffend **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 10.4 Häufigkeit und Prozess für Testen und erneute Bewertung von KI-Systemen etablieren

10.4.1 – Prozess

Mechanismen zur laufenden Überprüfung der Modellleistung einführen (zeit- oder ereignisbasiert)

Prozessprüfung

Dokumentarischer Nachweis der etablierten Häufigkeit und des Prozesses

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation physischer Tests

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

Kriterium 10.5 Sicherstellen, dass zuständige Parteien berücksichtigt haben, wie das KI-System Menschen in Entscheidungsprozessen zugutekommt

10.5.1 – Prozess

Erklärung zur Transparenz darüber, wie und wo das KI-System den Menschen ergänzt oder ersetzt

Prozessprüfung

Dokumentarischer Nachweis der Transparenzerklärung

Abgeschlossen: Nein **Kennzahl/Nachweisart:** 1) Interne Dokumentation (Verfahrenshandbuch) 2) Externe/interne Korrespondenz

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

INKLUSIVES WACHSTUM, GESELLSCHAFTLICHES & ÖKOLOGISCHES WOHLERGEHEN

Kriterium 11.1 Sicherstellen, dass die Entwicklung des KI-Systems dem Nutzen von Individuen, Gesellschaft und Umwelt dient

11.1.1 – Prozess

Prozess einführen, um festzustellen, dass Entwicklung und Bereitstellung dem Nutzen von Mensch, Gesellschaft und Umwelt dienen

Prozessprüfung

Dokumentarischer Nachweis der Berücksichtigung von Auswirkungen (menschliche Fähigkeiten, Arbeitsplätze, Kreativwirtschaft, Diskriminierung, Umwelt)

Abgeschlossen: Ja **Kennzahl/Nachweisart:** Interne Dokumentation (Verfahrenshandbuch)

Erläuterung: *Dies ist eine Beispiel-Erläuterung.*

FAIRNESS-TEST

Bei Fairness geht es darum, KI-Systeme so zu gestalten, dass die Entstehung oder Verstärkung unfairer Verzerrungen vermieden wird, basierend auf der beabsichtigten Definition von Fairness für Einzelpersonen oder Gruppen, die mit den gewünschten Ergebnissen des KI-Systems übereinstimmt.

In diesem technischen Test erzeugt das Tool Fairness-Kennzahlen. Je nach Anwendungsfall und Modelltyp können Nutzer die relevante(n) Kennzahl(en) auswählen.

Fairness für Klassifikation

Der Test zeigt, wie korrekt das Modell das ausgewählte sensible Merkmal (Geschlecht) vorhergesagt hat. Die folgende Tabelle listet die im Bericht erzeugten Fairness-Kennzahlen.

Fairness-Kennzahl	Beschreibung
False Negative Rate Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil falscher Vorhersagen unter den tatsächlich positiven Werten.
False Positive Rate Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil falscher Vorhersagen unter den tatsächlich negativen Werten.
False Discovery Rate Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil falscher Vorhersagen unter den als positiv vorhergesagten Werten.
False Omission Rate Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil falscher Vorhersagen unter den als negativ vorhergesagten Werten.
True Positive Rate Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil korrekter Vorhersagen unter den tatsächlich positiven Werten.
True Negative Rate Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil korrekter Vorhersagen unter den tatsächlich negativen Werten.
Positive Predictive Value Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil korrekter Vorhersagen unter den als positiv vorhergesagten Werten.
Negative Predictive Value Parity	Differenz zwischen zwei Gruppen, basierend auf dem Anteil korrekter Vorhersagen unter den als negativ vorhergesagten Werten.

Kennzahl (gender:0 vs. gender:1)		Wert		Wert
False Negative Rate	Klasse 0	0,013	Klasse 1	0,028
False Positive Rate	Klasse 0	0,028	Klasse 1	0,013
False Discovery Rate	Klasse 0	0,04	Klasse 1	0,01
False Omission Rate	Klasse 0	0,01	Klasse 1	0,04
True Positive Rate	Klasse 0	0,02	Klasse 1	0,008
True Negative Rate	Klasse 0	0,008	Klasse 1	0,02
Positive Predictive Value Parity	Klasse 0	0,026	Klasse 1	0,006
Negative Predictive Value Parity	Klasse 0	0,006	Klasse 1	0,026
Equal Selection Parity	Klasse 0	12	Klasse 1	6

Disparate Impact	Klasse 0	1,022	Klasse 1	0,988

Die angezeigten Kennzahlen zeigen die Gleichheit zwischen zwei Untergruppen. Bei mehr als zwei Untergruppen wird der Paritätswert durch Vergleich der Untergruppe mit dem kleinsten und der mit dem größten Wert bestimmt.

- Disparate Impact: Je näher der Wert bei 1 liegt, desto besser.
- Equal Selection Parity: Je kleiner der Wert, desto besser.
- Andere Fairness-Kennzahlen: Je kleiner der Wert, desto besser.

ROBUSTHEITSTEST

Robustheit erfordert, dass KI-Systeme ihr Leistungsniveau unter allen Umständen aufrechterhalten, einschließlich möglicher Änderungen der Betriebsumgebung oder des Vorhandenseins anderer (menschlicher oder künstlicher) Akteure, die adversariell interagieren.

In diesem technischen Test erzeugt das Tool Leistungskennzahlen bei Eingabe gestörter Testdatensätze. Je nach Anwendungsfall können adversarielle Störungen und/oder natürliche Korruptionen untersucht werden.

Die Robustness Toolbox verwendet den Boundary Attack: Zunächst wird gezielt eine große Menge Rauschen (Salt-and-Pepper) hinzugefügt, um eine Fehlklassifizierung zu erzwingen; anschließend wird das Rauschen reduziert, während die Fehlklassifizierung erhalten bleibt. Der Algorithmus ist unabhängig von Architektur/Parametern des Modells und wurde ursprünglich für Bilddaten entwickelt, ist aber auch auf tabellarische Daten anwendbar (mit Vorsicht bei der Interpretation, da nicht ausreichend getestet).

Ergebnisse

- Gesamtzahl der Stichproben: 2500
- Erfolgreiche Störungsrate: 100,00 %

Original- und gestörter Datensatz erzielten eine Genauigkeit von 50 % bzw. 26 %. Ein robustes Modell würde für beide Datensätze ähnliche Genauigkeit erzielen.

Beispiel einer gestörten Stichprobe und ihres vorhergesagten Werts

Hinweis: Die gestörte Stichprobe war möglicherweise nicht erfolgreich darin, die Vorhersage zu ändern. 5 von 8 Merkmalen werden unten gezeigt.

Merkmal	age	gender	income	race / Prediction
Original #0	86	1	64570	2 / 1
Gestört #0	0	233600,63	154520,65	37768,28 / 0

Empfehlung(en): Da das Ausmaß des Genauigkeitsrückgangs (24,08 %) als groß gilt, können Methoden zur Verbesserung der Robustheit untersucht werden — z. B. Hinzufügen von Rauschen und Datenaugmentierung während des Trainings, sowie eine Neubewertung der gesamten Bereitstellung.

ERKLÄRBARKEITSTEST

Bei Erklärbarkeit geht es darum sicherzustellen, dass KI-getriebene Entscheidungen von denjenigen, die das System nutzen, so weit wie möglich erklärt und verstanden werden können. Der erforderliche Grad an Erklärbarkeit hängt von Kontext, Stakeholder-Bedürfnissen, Verständnisart, Erklärungsform sowie der Schwere möglicher Folgen fehlerhafter Ausgaben ab.

In diesem technischen Test erzeugt das Tool auf Merkmalsbeiträgen basierende Erklärungen (Feature Contributions) aus den Testdaten und dem Modell.

SHAP

SHAP erklärt, wie sich Merkmale auf die Gesamtvorhersagen auswirken, unter Verwendung von Shapley-Werten. Die y-Achse zeigt die Merkmale, geordnet nach Beitrag; die x-Achse zeigt den absoluten durchschnittlichen SHAP-Wert über alle Vorhersagen. Farben repräsentieren die Ausgabeklassen.

Aus den Ergebnissen geht hervor, dass loan_amount am meisten zu den Gesamtvorhersagen beigetragen hat (höchster SHAP-Wert) — der wichtigste Einflussfaktor auf die Modellvorhersagen. Eine ähnliche Analyse gilt für die übrigen Merkmale.

Empfehlung(en): Merkmale mit höchstem und niedrigstem Beitrag überprüfen. Extrem hoher Beitrag kann zu Overfitting führen, extrem niedriger Beitrag zu unnötigem Effizienz-Overhead.