Data-as-a-Product

Warum verlässliche KI mit Ownership, Qualitätsstandards und Dokumentation beginnt

DEFINITION

Datenprodukte sind domänenspezifische, wiederverwendbare und klar verantwortete Datenbausteine, die bereichsübergreifend genutzt werden können.

Sechs Eigenschaften machen Daten zum Produkt

1 Auffindbar
dokumentiert und beschrieben, z. B. im Datenkatalog

2 Eigenständig wertvoll
klarer fachlicher Zweck und Nutzen

3 Interoperabel
mit anderen Datenprodukten kombinierbar

4 Klare Verantwortlichkeit
ein benannter Owner im Fachbereich

5 Zugänglich
„Plug & Play" über definierte Schnittstellen

6 Nutzerorientiert
für mehrere Konsumenten gebaut, nicht für ein Projekt

Für KI besonders wichtig: Qualität ist messbar vereinbart, und die Herkunft der Daten ist nachvollziehbar.

Der Lebenszyklus: Verantwortung endet nicht mit dem Go-live

1 Design

Wer nutzt es, wofür?

- Konsumenten und Zweck klären
- Owner benennen
- Datenvertrag entwerfen

2 Build

Umsetzen und absichern

- Pipelines aufbauen
- Qualitätsregeln testen
- Dokumentation erstellen

3 Run

Betreiben und verbessern

- Monitoring und SLA
- Feedback der Nutzer
- Versionierte Änderungen

4 Retire

Geordnet stilllegen

- Konsumenten informieren
- Archivieren oder abschalten
- Doku aktualisieren

Der Datenvertrag macht das Qualitätsversprechen überprüfbar

Eine Vereinbarung zwischen Anbieter (Owner) und Konsumenten. Offene Standards wie der **Open Data Contract Standard (ODCS)** geben die Struktur vor.

1 **Schema und Bedeutung** · Felder, Einheiten, Definitionen

2 **Qualitätsregeln** · Vollständigkeit, Aktualität, Wertebereiche

3 **Transformationen** · Was wird gefiltert, aggregiert, gelöscht?

4 **Verantwortung und SLA** · Owner, Support, Reaktionszeiten

5 **Version und Status** · Änderungen kontrolliert und angekündigt

```
datenprodukt: vibration_pumpenlinie_3
owner: Leitung Instandhaltung
status: active     version: 1.2.0
schema:
  - feld: vibration_rms
    einheit: mm/s
    abtastung: 1 kHz, Rohsignal
qualitaet:
  - vollstaendigkeit: >= 99,5 %
  - aktualitaet: <= 5 min
transformationen:
  - keine (Filter nur in Auswertungen)
sla: Störung < 4 h, Mo–Fr
```

Vereinfachtes Beispiel, angelehnt an ODCS

Die 5 Datenfallen und die 3 Prinzipien

Woran Sie Datenprobleme früh erkennen, und was dagegen hilft

Die 5 Datenfallen mit Selbstcheck

DATENFALLE	TYPISCHES SYMPTOM	GEGENMITTEL	BEI UNS?
1 Gefilterte Realität Selection- und Exclusion-Bias	Die Vorverarbeitung entfernt genau die relevanten Signale; die Stichprobe ist nicht repräsentativ.	Rohdaten sichern, Transformationen dokumentieren, Fachbereich prüft die Filterlogik.	☐
2 Trainingsdaten ≠ Betrieb Drift	Sensortausch, neue Kalibrierung oder Prozessänderung: Das Modell wird schleichend schlechter.	Drift und Datenfrische überwachen, Modell regelmäßig gegen neue Daten prüfen.	☐
3 Seltene Ereignisse fehlende Labels	Ausfälle sind selten, Ursachen stehen nur im Freitext des Wartungsprotokolls.	Labeling mit Fachexperten, Ereignisse strukturiert erfassen, passende Gütemaße statt Trefferquote.	☐
4 Bedeutung unklar fehlende Semantik	Spalte „Temp“: welche Einheit, welcher Messpunkt? Gleiche Begriffe, unterschiedliche Definitionen.	Glossar oder Datenkatalog, semantische Schicht mit verbindlichen Definitionen.	☐
5 Niemand verantwortlich Ownership-Lücke	Bei Fehlern zeigen IT und Fachbereich aufeinander; das Modell verwaist nach dem Projekt.	Benannter Data Owner im Fachbereich, Datenvertrag.	☐

Auswertung: Zwei oder mehr Kreuze? Dann lohnt es sich, vor dem nächsten KI-Vorhaben mit Prinzip 1 zu beginnen: einen Owner für die wichtigsten Daten benennen.

Die 3 Prinzipien für datengetriebene KI-Projekte

1 Jedes Datenprodukt hat einen Owner, und zwar im Fachbereich, nicht in der IT.

Der Owner kennt die Bedeutung der Daten und verantwortet ihre Qualität. Die IT betreibt die Technik.

2 Qualität wird vereinbart und gemessen, nicht angenommen.

Ein Datenvertrag hält Schema, Bedeutung, Vollständigkeit, Aktualität und bekannte Filter und Transformationen fest. Geprüft wird vor dem Modell, nicht danach.

3 Herkunft und Weg der Daten sind dokumentiert (Lineage).

Nur so lassen sich Fehler finden. Zugleich ist es die Grundlage für Nachweise nach EU AI Act Art. 10 (Daten-Governance bei Hochrisiko-Systemen) und ISO/IEC 42001.

gollnickdata.de

Ihr Data-Product-Steckbrief

Beschreiben Sie einen eigenen Datenbestand als Produkt.

Name des Datenprodukts
z. B. „Vibrationsdaten Pumpenlinie 3“, „Reklamationen“, „Kundenstamm“

Datum / Version

Owner
Wer ist fachlich verantwortlich? (Rolle, nicht Person)

Konsumenten
Wer nutzt die Daten: Reports, KI-Modelle, Teams?

Quelle und Weg
Woher kommen die Daten, welche Systeme durchlaufen sie?

Transformationen und Filter
Was wird unterwegs aggregiert, gefiltert oder gelöscht?

Bedeutung (Semantik)
Einheiten, Definitionen, Glossar: Was bedeutet welches Feld?

Zugang
Wie und wo greifen Konsumenten zu? Wer darf was?

Qualitätsversprechen
messbar formuliert, z. B. „Vollständigkeit ≥ 99,5 %“, „Aktualität ≤ 5 Minuten“

Vollständigkeit

Aktualität

Genauigkeit / Wertebereiche

Bekannte Lücken und Risiken
Welche Datenfalle droht?

- [ ] 1 Gefilterte Realität
- [ ] 2 Trainingsdaten ≠ Betrieb
- [ ] 3 Seltene Ereignisse
- [ ] 4 Bedeutung unklar
- [ ] 5 Niemand verantwortlich

Mein nächster Schritt
Mit wem kläre ich den Owner, und bis wann?

Hinweis: Wenn Sie den ausgefüllten Steckbrief teilen, tragen Sie bitte keine vertraulichen oder personenbezogenen Daten ein. Rollen und Kategorien reichen.

Weiterführende Quellen

Quellen und Standards zum Workshop

Standards und Leitfäden

Open Data Contract Standard (ODCS)	Offener Standard für Datenverträge (Bitol-Projekt der Linux Foundation): Schema, Qualität, SLA, Rollen in YAML.
EU AI Act, Art. 10	Anforderungen an Daten und Daten-Governance für Hochrisiko-KI-Systeme: Herkunft, Aufbereitung, Bias-Prüfung, Repräsentativität.
ISO/IEC 42001	Managementsystem für KI: Rollen, Verantwortlichkeiten, Risiken und Datenqualität über den Lebenszyklus.
Data Ethics Canvas	Arbeitsblatt des Open Data Institute (ODI), um Datenvorhaben auf ethische Fragen und Auswirkungen zu prüfen.